Méthode du plus proche voisinage

DEMARS et NICOSIA

May 30, 2015

Nous présentons ici une alternative de la méthode des plus proches voisins, que nous appelons **plus proche voisinage**, et qui peut se révéler plus efficace dans certaines situations, comme lors du challenge prédictif par Actulab en mai 2015.

L'objectif consistait à prédire le score final de joueurs de golf (correspondant à la somme de sess scores sur les 18 trous du parcours) à partir d'un nombre non-prédéfini de scores que le joueur aurait déjà effectué. Voici par exemple 10 joueurs parmis les 600 dont nous devions prédire au mieux le score final :

```
##     hole_1 hole_2 hole_3 hole_4 hole_5 hole_6 hole_7 hole_8 hole_9 hole_10
## 66       4      4      5      3      6      3      4      4     NA       NA
## 64       5      5      5      3      7      4      4      3     NA       NA
## 482      4      4      4      3      5      5      4      3     NA        4
## 77       6      4      4     NA     NA     NA     NA     NA     NA       NA
## 116     NA     NA     NA     NA     NA     NA      4      3      4        5
## 60       4      3      4      3      6      6      3      3     NA       NA
##     hole_11 hole_12 hole_13 hole_14 hole_15 hole_16 hole_17 hole_18 TOTAL
## 66        7       4       3       3       3       5       3       4    NA
## 64       NA       4       3       5       3       5       4       6    NA
## 482       6       5       4       4       3       3       3       4    NA
## 77       NA      NA      NA      NA      NA      NA       4       4    NA
## 116       4       4       5      NA      NA      NA      NA      NA    NA
## 60       NA      NA      NA       4       3       4       3       4    NA
```

Nous avions à notre disposition un jeu d'apprentissage de 2000 joueurs ayant totalement complété les 18 trous, que nous avons séparé en deux afin de sélectionner le meilleur modèle par validation croisée. Le modèle que nous présentons ici, vainqueur de la compétition, est celui ayant obtenu le meilleur RMSE moyen, de 1.02, réalisé sur plus de 500 découpages aléatoires de la base des 200 joueurs.

Principe et code

Le principe est très simple, proche de la méthode des k plus proches voisins. Voici les étapes pour un joueur, prenons par exemple le joueur 116 de la table ci-dessus :

1. Calcul de la distance entre ce joueur et les 2000 de la base d'apprentissage. Cette distance est uniquement calculée sur les trous remplis, ce qui signifie que les trous que notre joueur n'a pas encore effectué ne sont pas pris en compte (option na.rm=T). On s'intéresse alors à la plus petite de ces distances.

```
distance = apply(score, 1, function(x) sum(abs(joueur-x),na.rm=T))
min = min(distance)
(min)
```

```
## [1] 1
```

2. Sélection des joueurs dont la distance est égale à la distance minimale, qui vaut 1 pour cet exemple. Il peut n'y avoir qu'un seul joueur dont la distance est minimale, comme il peut y en avoir des dizaines. Le nombre de voisins choisis n'est donc pas prédéfini.

```
relatives = which(distance==min)
(relatives)
```

```
##  210  230  504 1162 1432 1454
##  210  230  504 1162 1432 1454
```

3. Imputation, pour chaque trou non remplis de notre joueur, par la moyenne obtenu à ce trou par le(s) voisin(s) de distance minimale (il y en a 6 pour ce cas). Pour notre application, la distance la plus efficace en terme de RMSE était la distance de Manhattan.

```
ind = is.na(joueur)
if(length(relatives)==1){
  joueur[ind] = score[relatives,ind]
} else{
  joueur[ind] = apply(score[relatives,ind],2,mean)
}
```

4. Prédiction comme la somme des trous connus de notre joueur et des trous remplacés par la moyenne des voisins de distance minimale.

```
joueur["TOTAL"] = sum(joueur)
```

```
##            hole_1   hole_2   hole_3   hole_4 hole_5 hole_6 hole_7 hole_8
## joueur         NA       NA       NA       NA     NA     NA      4      3
## prediction      4 3.833333 4.166667 3.833333    5.5    3.5      4      3
##            hole_9 hole_10 hole_11 hole_12 hole_13  hole_14  hole_15
## joueur          4       5       4       4       5       NA       NA
## prediction      4       5       4       4       5 3.833333 4.333333
##            hole_16  hole_17 hole_18    TOTAL
## joueur          NA       NA      NA       NA
## prediction       4 3.166667     5.5 74.66667
```

Pour cette application, il n'était pas requis de tronquer les données afin d'obtenir des prédictions entières, mais si tel est le cas, un seuil pour cette étape peut être obtenu par validation croisée à l'aide de la base d'apprentissage.